

Федеральное государственное бюджетное образовательное  
учреждение высшего профессионального образования  
**«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ МОРДОВ-  
СКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ им. Н.П.ОГА-  
РЕВА»**

Факультет математики и информационных технологий  
Кафедра прикладной математики, дифференциальных уравнений и тео-  
ретической механики

**ВАСИЛЬКИН НИКОЛАЙ ВИКТОРОВИЧ**

**Научный доклад на тему:**

**«РАЗРАБОТКА НЕЙРОСЕТЕВЫХ МОДЕЛЕЙ ДЛЯ АНАЛИЗА  
УПРАВЛЯЕМЫХ ПРОЦЕССОВ»**

Направление подготовки 01.06.01 — Математика и механика,  
Профиль подготовки — Дифференциальные уравнения, динамические  
системы и оптимальное управление.

Научный руководитель работы

канд. физ.-мат. наук, доцент

**Т.Ф. Мамедова**

Саранск

2018

## ОБЩАЯ ХАРАКТЕРИСТИКА РАБОТЫ

**Актуальность темы.** В настоящее время проблема исследования временных рядов, является одной из самых важных и значительных направлений во многих областях науки. Точное определение прогнозируемых значений временного ряда на основе его исторических значений крайне необходимо в экономической, логистической, торговой и во многих других сферах деятельности человека. Сегодня использование данных полученных в результате моделирования прогнозируемых крайне необходимы, а иногда и жизненно важны практически во всех сферах деятельности человека.

На сегодняшний день по всему миру много научных центров и крупных компаний занимаются накоплением исторических показателей в своих базах данных, что непременно приведет к повышению объема накопленной информации, которая так необходима для решения задач прогнозирования.

Проблема анализа и получения прогноза для временного ряда возможно решить через построение модели, которая сможет максимально правильно описать исследуемых нами процесс. В мире представлено довольно большое количество моделей, с помощью которых можно исследовать временной ряд: регрессионные и авторегрессионные модели, нейросетевые модели, модели экспоненциального сглаживания, модели на базе цепей Маркова, классификационные модели и др. Из всех моделей можно выделить классы авторегрессионных и нейросетевых моделей, которые являются наиболее точными и универсальными для решения поставленной задачи.

**Целью работы** является создание новой модели и метода прогнозирования, который можно будет отнести к классу авторегрессионных моделей. В новой модели необходимо избавиться от одного из самых главных недостатков моделей – большое число неучтенных свободных параметров. Построенная модель и соответствующий ей метод прогнозирования должен обладать большой скоростью получения прогнозных значений и иметь крайне высокую точность прогнозирования.

**Методы исследования.** Для решения поставленных задач создания новой модели и метода прогнозирования в работе применены методы регрессионного анализа, методы математического моделирования, методы анализа временных рядов, нейросетевые модели и объектно-ориентированное программирование.

**Теоретическую основу** данной работы составили труды следующих авторов: Дж. Бокса; С. Хайкина; И. А. Чучуева.

**Научная новизна.** В научно-квалификационной работе (диссертации) получены следующие основные результаты, которые выносятся на защиту.

- 1) Модель экстраполяции временных рядов по выборке максимального подобия, относящаяся к классу авторегрессионных моделей и имеющая единственный параметр.
- 2) Метод прогнозирования на основании применения нейросетевых моделей для вычисления коэффициентов линейной корреляции Пирсона, что является нововведением в данной модели и существенно повышает точность нахождения прогнозных значений.
- 3) Результаты прогнозирования временных рядов показателей энергопотребления в зависимости от параметров.

**Достоверность** прогнозирования временных рядов на модели экстраполяции подтверждается тем, что полученные результаты прошли сравнение с достоверными данными рядов и имеют минимальную ошибку регрессии, по сравнению с другими методами.

**Практическая ценность.** Разработанный метод прогнозирования по выборке максимального подобия могут применять для прогнозирования временных рядов различных предметных областей. Разработанные алгоритмы экстраполяции временных рядов с учетом внешних факторов наглядны и удобны для программной реализации. Точность вычисления прогнозных значений при использовании модели увеличена.

**Апробация работы.** Работа прошла соответствующую апробацию. Основные результаты отражены в шести публикациях, среди которых две публикации в изданиях, рекомендованных ВАК, а также докладывались на научно-практических конференциях молодых ученых, аспирантов и студентов Национального исследовательского Мордовского государственного университета им. Н. П. Огарева.

**Структура и объем диссертации.** Работа состоит из введения, четырех глав, заключения, списка литературы (24 наименования), трех приложений. Работа изложена на 79 страницах, содержит 4 рисунка и 4 таблицы.

## КРАТКОЕ СОДЕРЖАНИЕ РАБОТЫ

**Во введении** приводится подтверждение важности и актуальности проблемы исследования. В научно-квалификационной работе, приводится исследование по тематике актуальности и представлено по возможности краткое описание методов исследования и перечислено содержание работы.

**В первой главе** рассматриваются методы и теории, которые применимы при исследовании временного ряда. В главе приводятся самые главные определения теории, и сформулирована постановка задачи прогнозирования временных рядов с учетом внешних факторов.

В результате исследования сделан вывод, что на сегодняшний день создано довольно большое количество моделей для прогнозирования временных рядов. Выявлено, что наиболее многообещающим направлением развития моделей прогнозирования с целью повышения точности является создание комбинированных моделей, выполняющих на первом этапе кластеризацию, а затем прогнозирование временного ряда внутри установленного кластера.

**Во второй главе** представлена образец экстраполяции временных рядов по выборке максимального подобия для постановки задачи с учетом внешних факторов.

Рассмотрим временной ряд  $Z(t) = Z(1), Z(2), \dots, Z(t)$ . Набор последовательных значений,  $Z_t^M = Z(t), Z(t+1), \dots, Z(t+M+1)$ , который находится внутри данного временного ряда, назовем выборкой длины  $M$  с момента начала отсчета  $t$ ;  $M \in \{1, 2, \dots, T\}$ ,  $t \in \{1, 2, \dots, T-M+1\}$ . Получается, что выборкой является часть временного ряда, который имеет начало отсчета и длину. Две выборки равной длины, которые принадлежат одному временному ряду, представим через временную задержку  $Z_t^M = Z(t), \dots, Z(t+M-1)$  и  $Z_t^M = Z(t), \dots, Z(t-k+M-1)$ , где  $k \in \{1, 2, \dots, t-1\}$ . Так как речь идет о векторах, то будем использовать обозначение  $Z_t^M$ . В результате проведенного исследова-

ния моделей был сделан вывод: «Построение моделей временных рядов на основе выборок, предполагает за собой, что временной ряд можно представить, как последовательность выборок. На практике можно заметить, что некоторые участки временного ряда подобны с будущими выборками». Приведенное свойство использовано при исследовании модели временных рядов.

Теперь, применив приведенное свойство, аппроксимируем более позднюю выборку  $Z_t^M$  при помощи предшествующей выборки  $Z_{t-k}^M$

$$Z_t^M = \alpha_1 Z_{t-k}^M + \alpha_0 I^M + E^M \quad (1)$$

Выражение (1) возможно переписать:

$$\hat{Z}_t^M = \alpha_1 Z_{t-k}^M + \alpha_0 I^M \quad (2)$$

В выражении (2) приведенные  $\alpha_1$  и  $\alpha_0$ - коэффициенты,  $I^M$  - единичный вектор,  $E^M$  - вектор значений ошибок аппроксимации.

Пусть дана линейная зависимость (1), тогда функция ошибки аппроксимации  $S_k^M$  для выборок  $Z_t^M$  и  $Z_{t-k}^M$  с задержкой  $k$  можно записать в виде:

$$S_k^M(\alpha_1, \alpha_0) = \sum_{t=0}^{M-1} (Z(T+i) - \alpha_1 Z(t-k+i) - \alpha_0)^2 \quad (3)$$

Здесь,  $S_k^M(\alpha_1, \alpha_0)$  – это функция суммы квадратов. Теперь необходимо, подобрать такие значения  $\alpha_1$  и  $\alpha_0$ , чтобы подставив их в формулу (3) получить минимальное  $S_k^M(\alpha_1, \alpha_0)$ . Решение задачи приведено с помощью метода наименьших квадратов.

Рассмотрим временной ряд  $Z(t)$  и некоторую выборку  $Z_t^M$ , которая принадлежит временному ряду. Необходимо получить все значения  $S_k^M(\alpha_1, \alpha_0)$  для  $k \in \{1, 2, \dots, t-1\}$ ,  $M = \text{const}$ . Теперь найдем минимальное значение  $Z_t^M$ :

$$S_{k \min}^M = \min(S_1^M, S_2^M, \dots, S_{t-1}^M) \quad (4)$$

Получим, что минимальная ошибка регрессии  $S_{k \min}^M$  равна максимальному значению модуля линейной корреляции между исходной выборкой

$Z_t^M$  и модельной  $\hat{Z}_t^M$ . То есть, для  $k \in \{1, 2, \dots, t-1\}$  и  $M = \text{const}$  определим множество значений модуля линейной корреляции

$$\rho_k^M = \left| \rho(\hat{Z}_t^M, Z_t^M) = \frac{\sum_{i=1}^M (\hat{Z}(t+i) - \bar{Z})(Z(t+i) - \bar{Z})}{\sqrt{\sum_{i=1}^M (\hat{Z}(t+i) - \bar{Z})^2 \sum_{i=1}^M (Z(t+i) - \bar{Z})^2}} \right| \in [0, 1], \quad (5)$$

после чего, возможно определить максимальное значение множества

$$\rho_{k \max}^M = \max(\rho_1^M, \rho_2^M, \dots, \rho_{t-1}^M), \quad (6)$$

Задержка  $k_{\min}$  из выражения (4) и задержка  $k_{\max}$  из выражения (6) будут равны между собой, т.е.  $k_{\min} = k_{\max}$ .

Приведенную в (4) или (6) задержку, соответствующую минимуму ошибки регрессии  $S_{k \min}^M$  и максимуму модуля корреляции  $\rho_{k \max}^M$  обозначим  $k_{\max}$  а выборку  $Z_{t-k \max}^M$  назовем выборкой максимального подобия. Выборка максимального подобия  $Z_{t-k \max}^M$  является выборкой, которая при подстановки в уравнение (2) дает в результате значения выборки  $\hat{Z}_t^M$ , которая максимально точно описывает исходную выборку  $Z_t^M$ .

В работе сформулирована следующая гипотеза подобия: если исходная выборка  $Z_t^M$  и модельная выборка  $\hat{Z}_t^M$ , полученная на основании (2) с использованием выборки  $Z_{t-k \max}^M$  имеют значения величины  $\rho_{k \max}^M$ , близкое к единице, то для некоторых значений  $P$  и выборок  $\rho_{k \max}^{M+\rho}$ ,  $Z_t^{M+P}$  значение величины  $\rho_{k \max}^{M+\rho}$  также близко к единице.

В данный момент не существует единственной возможности получения коэффициентов линейной корреляции, значения которых приближались бы к единице. В работе изложен метод получения коэффициентов с помощью многослойной нейронной сети с алгоритмом обучения, основанным на принципе обратного распространения ошибки. Подробно принцип изложен в третьей главе.

Задача получения прогнозного значения временного заключается в определении  $\hat{Z}_{T+1}^P$  прогнозируемых значений ряда  $Z(t)$ , при учете внешних факторов, которые выражены в виде временных рядов  $X_1(t), \dots, X_S(t)$ .

В первую очередь определим модель аппроксимации. Необходимо для времени  $T$  получить значение  $P$   $Z(T+1), Z(T+2), \dots, Z(T+P)$ .

Воспользовавшись приведенными свойством выборок, становится возможным описать выборку  $\hat{Z}_{T+1}^P$  через  $Z_T^P$ , которая принадлежит ряду  $Z_T^P$

$$\hat{Z}_{T+1}^P = \alpha_1 Z_T^P + \alpha_0 I^P, \quad (7)$$

Приведем решение задачи:

1. Найдем максимально подобную выборку для  $Z_{T-M+1}^M$  (рис.1)

Для этого переберем все возможные задержки  $k \in \{1, 2, \dots, T-M-1\}$ . Для  $k$  теперь необходимо решить задачу (1), после решения которой возможно получить значения  $\alpha_1$  и  $\alpha_0$ , соответствующие  $k$ . Далее получаем значение модельной выборки,  $\hat{Z}_{T-M+1}^P$  на основании которых получаем значение  $\rho_k^M$  (5). Далее определяем значение  $\rho_{kmax}^M$  по выражению (6) и выборке максимального подобия  $Z_{T-M+1-kmax}^M = Z_{kmax}^M$ .

2. Найдем выборку  $Z_T^P$  (выборка Базовая история, рис. 1).

В соответствии с формулировкой, в качестве  $Z_T^P$  используем выборку  $Z_{kmax+M}^P$ , которая располагается вслед за выборкой максимального подобия..

3. Рассчитываем выборку  $\hat{Z}_{T+1}^P$  (выборка прогноз, рис. 1).

Значения выборки  $\hat{Z}_{T+1}^P$  рассчитаем по формуле

$$\hat{Z}_{T+1}^P = \alpha_1 Z_{kmax+M}^P + \alpha_0 I^P = EMMSP(M), \quad (8)$$

которая представляет собой модель экстраполяции временных рядов по выборке максимального подобия. Приведенные выборки изображены на рисунке 1.






Рисунок 1. – Положение выборок на оси времени при экстраполяции временного ряда

Далее становится возможным добавить внешние факторы. Похожим образом приведем формулу:

$$\hat{Z}_t^M = \alpha_{s+1} Z_{t-k}^P + \alpha_s X_{(s)t}^M + \dots + \alpha_1 X_{(1)t}^M + \alpha_o I^M \quad (9)$$

Пусть  $\hat{Z}_T^P$  можно найти на основании формулы (9), тогда все последующие значения  $S_k^M(a_{s+1}, \dots, a_0)$  для  $k \in \{1, 2, \dots, t-1\}$  и  $M = \text{const}$ . Далее в последовательности значений  $S_k^M$  становится возможным найти минимальное для выражения (4). Как и в предыдущем примере, минимальная ошибка регрессии  $S_{kmin}^M$  будет соответствовать максимальному модулю коэффициента линейной корреляции  $\rho_{kmax}^M$  (6).

Похожим образом приведем выборку максимального подобия  $Z_{t-kmax}^M$ . Подставив значения  $Z_{t-kmax}^M$  в уравнение (9) получим значение  $\hat{Z}_T^P$ , которое как можно точнее описывает начальную выборку  $Z_t^M$  с учетом внешних факторов  $X_{(1)}^M, \dots, X_{(s)t}^M$ .

Для получение значений выборки прогноза  $\hat{Z}_{T+1}^P$  и учитывая влияние внешних факторов, которые так же можно записать в виде рядов  $X_1(t), \dots, X_s(t)$ , может юить применим алгоритм аналогичный предыдущему

случаю. Представим выборку прогноза исходного временного ряда  $Z_t^T$  и выборки  $X_{(1)T+1}^P, \dots, X_{(S)T+1}^P$  следующим образом:

$$\hat{Z}_{T+1}^P = \alpha_{S+1} Z_T^P + \alpha_S X_{(S)T+1}^P + \dots + \alpha_1 X_{(1)T+1}^P + \alpha_o I^P \quad (10)$$

Решение поставленной задачи можно провести в три действия.

1. Рассчитаем выборку максимального подобия для выборки новой истории  $Z_{T-M+1}^M$  (выборка Новая история, рис. 2).

Выборку максимального подобия  $Z_{kmax}^M$  определяем аналогично предыдущему случаю.

2. Получим  $Z_T^P$  (базовая история, рис.2) Базовую выборку  $Z_T^P$  определяем как и в предыдущем случае.

3. Находим выборку  $\hat{Z}_{T+1}^P$  (выборка Прогноз, рис.2). Значения выборки  $\hat{Z}_{T+1}^P$  определяем по формуле

$$\hat{Z}_{T+1}^P = \alpha_{S+1} Z_{kmax+M}^P + \alpha_S X_{(S)T+1}^P + \dots + \alpha_1 X_{(1)T+1}^P + \alpha_o I^P = EMMSPX(M), \quad (11)$$

которая представляет собой расширенную модель экстраполяции временных рядов по выборке максимального подобия. (рис. 2).

В этой главе показано, что точность нахождения указывается в процентах.

$$MAPE = \frac{1}{M} \sum_{i=t}^{t+M-1} \frac{|Z(i) - \hat{Z}(i)|}{Z(i)} 100\%, \quad (12)$$




Рисунок 2 –Положение выборок на оси времени при экстраполяции временного ряда с учетом одного внешнего фактора.

**В третьей главе** приведен метод нахождения коэффициентов линейной корреляции при помощи модели нейронной сети.

Каждый нейрон в составе нейронной сети имеет нелинейную функцию активации. Это функция является гладкой (т.е. всюду дифференцируемой). Формой активации является сигмоида

$$y_i = \frac{1}{1 + \exp(-\gamma_i)}, \quad (13)$$

где  $\gamma$  - локальное поле (т.е. взвешенная сумма всех синаптических входов плюс пороговое значение) нейрона;  $y_i$  - выход нейрона.

Нейронная сеть состоит из слоев скрытых нейронов, которые не являются частью входа или выхода сети. Они помогают сети решать поставленные задачи, шаг за шагом получаю индивидуальные признаки из исходных данных.

В главе приводится алгоритм обратного распространения ошибки. Ошибку для нейрона  $j$  на повторении  $n$  (равен  $n$ -му шагу) можно привести в виде:

$$e_j(n) = d_j(n) - y_j(n), \quad (14)$$

Тогда, если взять сумму всех значений энергии ошибки, то получим:

$$E(n) = \frac{1}{N} \sum_{n=1}^N E(n) \quad (15)$$

Тогда значение  $\gamma_j(n)$ , которое является результатом функции активации, связанной с данным нейроном, равно

$$\gamma_j(n) = \sum_{i=0}^m \omega(n) y_j(n), \quad (16)$$

где  $m$  – все входы без нейрона  $j$ . Тогда вес  $w_{j0}$  (равный определенному входу  $y_0 = \pm 1$ ) совпадает с  $b_j$ , для нейрона  $j$ . Функциональный сигнал  $y_j(n)$  в результате равен:

$$y_j(n) = \varphi_j(\gamma_j(n)). \quad (17)$$

Алгоритм обратного распространения состоит в применении к синаптическому весу  $w_{ji}(n)$  коррекции  $\Delta\omega_{ji}(n)$ , пропорциональной частной производной  $\frac{\partial E(n)}{\partial \omega_{ji}(n)}$ . Представим градиент в формуле (18):

$$\frac{\partial E(n)}{\partial \omega_{ji}(n)} = \frac{\partial E(n)}{\partial e_j(n)} \frac{\partial e_j(n)}{\partial y_j(n)} \frac{\partial y_j(n)}{\partial v_j(n)} \frac{\partial v_j(n)}{\partial \omega_{ji}(n)}, \quad (18)$$

Производная  $\frac{\partial E(n)}{\partial \omega_{ji}(n)}$  является фактором, который направит в поиске веса  $\omega_{ji}(n)$ .

Продифференцируем две половины формулы (15) по  $e_j(n)$ :

$$\frac{\partial E(n)}{\partial \omega_{ji}(n)} = \frac{\partial E(n)}{\partial e_j(n)} \frac{\partial e_j(n)}{\partial y_j(n)} \frac{\partial y_j(n)}{\partial v_j(n)} \frac{\partial v_j(n)}{\partial \omega_{ji}(n)}. \quad (19)$$

Проделав операцию (14) по  $y_j(n)$ , получим результат:

$$\frac{\partial e_j(n)}{\partial y_j(n)} = -1, \quad (20)$$

Затем дифференцируя (17) по  $\gamma_j(n)$ , получим

$$\frac{\partial y_j(n)}{\partial v_j(n)} = \varphi'_j(v_j(n)), \quad (21)$$

Далее, продифференцировав (16) по  $w_{ii}(n)$ , рассчитаем

$$\frac{\partial v_j(n)}{\partial \omega_{ji}(n)} = y_j(n), \quad (22)$$

Подставляя результаты в формулу (18), получим окончательное выражение:

$$\frac{\partial E(n)}{\partial \omega_{ji}(n)} = -e_j(n) \varphi'(\nu_j(n)) y_j(n). \quad (23)$$

Теперь применив дельта правило для коррекции  $\Delta w_{ji}(n)$  получим:

$$\Delta \omega_{ji}(n) = -\eta \frac{\partial E(n)}{\partial \omega_{ji}(n)}, \quad (24)$$

где  $\eta$  - скорость обучения. При использовании градиентного спуска для области весов, необходимо использовать знак «минус». Это приведёт к уменьшению значения изменения энергии ошибки  $E(n)$ . Далее, подставив (23) в (24), получим

$$\Delta \omega_{ji}(n) = \eta \delta_j(n) y_j(n), \quad (25)$$

где локальный градиент определяется выражением

$$\delta_j(n) = -\frac{\partial E(n)}{\partial \nu_j(n)} = -\frac{\partial E(n)}{\partial e_j(n)} \frac{\partial e_j(n)}{\partial y_j(n)} \frac{\partial y_j(n)}{\partial \nu_j(n)} = e_j(n) \varphi'(\nu_j(n)). \quad (26)$$

Градиент показывает изменение синоптического веса. Исходя из (26) локальный градиент нейрона  $j$  равен произведению соответствующего сигнала ошибки  $e_j(n)$  этого нейрона и производной  $\varphi'(\nu_j(n))$  соответствующей функции активации. У нас довольно простой случай, так как для каждого выходного узла сети известен соответствующий желаемый отклик.

**В четвертой главе** разработан метод прогнозирования на базе модели экстраполяции и учетом внешних факторов по выборке максимального подобия.

Получены результаты прогноза для временного ряда энергопотребления. Полученные результаты внесены в таблицу 1.

Таблица 1 – Прогнозные значения на 24.04.2016 года

№	Дата (24.03.2016), ч.	Значения ряда, МВт/ч.	Прогнозные значения ряда МВт-ч.	MAE (MAPE) МВт-ч., (%)
1	1:00	2,013	2,023	(0,97)
2	2:00	2,075	2,086	(1,06)
3	3:00	2,192	2,203	(0,92)

4	4:00	2,308	2,325	(1,42)
5	5:00	2,416	2,436	0,65)
6	6:00	2,478	2,494	(1,24)
7	7:00	2,489	2,512	(1,37)
8	8:00	2,512	2,539	(1,23)
9	9:00	2,460	2,484	(1,27)
10	10:00	2,473	2,486	(0,35)
11	11:00	2,436	2,459	(1,46)
12	12:00	2,437	2,456	(1,57)
13	13:00	2,417	2,429	(0,81)
14	14:00	2,389	2,410	(1,25)
15	15:00	2,382	2,398	(1,12)
16	16:00	2,307	2,324	(1,24)
17	17:00	2,338	2,358	(1,36)
18	18:00	2,472	2,498	(1,47)
19	19:00	2,391	2,405	(1,15)
20	20:00	2,241	2,258	(1,23)
21	21:00	2,093	2,108	(1,15)
22	22:00	2,024	2,036	(1,12)
23	23:00	2,000	2,012	(1,17)
24	0:00	2,013	2,031	(1,43)

## **ОСНОВНЫЕ РЕЗУЛЬТАТЫ И ВЫВОДЫ:**

В результате выполнения научно-квалификационной работы, мною были получены следующие результаты.

Разработана новая модель прогнозирования временных рядов по выборке максимального подобия для постановки задачи моделирования и прогнозирования временного ряда с учетом внешних факторов. Применена нейронная сеть для определения коэффициентов линейной корреляции Пирсона. Новая модель относится к авторегрессионному классу моделей и имеет единственный параметр, что упрощает задачу идентификации модели, устраняя основной недостаток моделей данного класса.

Разработан новый метод прогнозирования на основе предложенной модели, содержащий набор алгоритмов, распознавании модели и создании прогнозных значений. Применена многослойная нейронная сеть с алгоритмом обучения обратного распространения ошибки.

Выполнена программная реализация разработанных алгоритмов.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- Бокс Дж. Анализ временных рядов, прогноз и управление/Дж. Бокс, Г. М. Дженкинс— М. : Мир, 1974.—406 с.
- I. A. Gheyas A Neural Network Approach to Time Series Forecasting // Proceedings of the World Congress on Engineering. —London, 2009.—1292 p.
- M. Norizan Short Term Load Forecasting Using Double Seasonal ARIMA Model // Regional Conference on Statistical Sciences.—Malaysia, Kelantan, 2010. —73 p.
- D. H. Mazengia Forecasting Spot Electricity Market Prices Using Time Series Models: Thesis for the degree of Master of Science in Electric Power Engineering.—Gothenburg, Chalmers University of Technology, 2008.—89 p.
- N. Morariu A neural network model for time series forecasting// Romanian Journal of Economic Forecasting. —USA, 2009.—223 p
- N. Draper Applied regression analysis.— New York: Wiley, In press, 1981.—693 p.
- S. K. Prajakta, Time series Forecasting using Holt-Winters Exponential Smoothing // Kanwal Rekhi School of Information Technology Journal.—Boston, 2004.—13p.
- Хайкин С. Нейронные сети: полный курс/С. Хайкин.— М. : ООО «И. Д. Вильямс», 2006.—1104 с.
- R. P. Pradhan Forecasting Exchange Rate in India: An Application of Artificial Neural Network Model // Journal of Mathematics Research.—USA, 2010.—117 p.
- B. Yildiz Forecasting the Istanbul Stock Exchange National 100 Index Using an Artificial Neural Network // An International Journal of Science, Engineering and Technology.—London, 2008,—39 p.
- J. Catalao An Artificial Neural Network Approach for Day-Ahead Electricity Prices Forecasting// 6th WSEAS international conference on Neural networks.—USA, Stevens Point, 2005.—83 p.



Семенов В. В. Математическое моделирование динамики транспортных потоков/В. В. Семенов.–М. : ИПМ им. М. В. Келдыша, 2004.–44 с.

W. Huang Forecasting stock market movement direction support vector machine// Elsevier: computers and operation research.–USA, New-York, 2005.–2522 p.

S. Mahfoud Financial Forecasting Using Genetic Algorithms // Applied Artificial Intelligence.–USA, 1996.–565 p.

F. J. Nogales Electricity price forecasting through transferfunction models // Journal of the Operational Research Society.–London, 2006.–356 p.

H. K. Alfares Electric load forecasting: literature survey and classification of methods // International Journal of Systems Science. –Gloster, 2002.–34 p.

H. R. Fogler A pattern recognition model for forecasting //Management science. 1974.–1189 p.

18. H. Zareipour Forecasting the Hourly Ontario Energy Price byMultivariate Adaptive Regression Splines // IEEE Power Engineering Society General Meeting.–Canada, Montreal, 2006.–7 p.

Мамедова Т.Ф., Василькин Н.В. М. Модель Солоу-Свона. Актуальные вопросы прикладной математики, 26.12.2012 г., Саранск, СВМО, стр. 12-17

Василькин Н.В. Задачи оптимального управления в экономике. Материалы конференции молодых ученых. Саранск, 2013 г.

Василькин Н.В. Задачи оптимального управления в экономике. Материалы Всероссийской конференции: Современные тенденции в развитии научной мысли. Саранск, 2013 г.

Мамедова Т.Ф., Василькин Н.В. Огарев-online. – 2015. – №23. – Режим доступа: <http://journal.mrsu.ru/arts/o-prognozirovanie-vremennogo-ryada-s-pomoshhyu-nejronnyh-setej.>, 6с.

Василькин Н.В., Катенин А.В., Новиков О.В. Проблемы разработки и создания территориально распределенных автоматизированных специальных систем управления связью. Научно-технический сборник АО «Концерн «Си-

стемпром», 2017, № 1(8). – Под ред. кандидата технических наук А.П. Мурзина. – М.: Издательство: «АО «Концерн «Системпром», 2017. – XXXXXXXXX. – 567 с. – Инв. № Д-2030с.

Василькин Н.В., Егорова Д.К., Мамедова Т.Ф., Метод покомпонентной асимптотической эквивалентности в задаче об устойчивости электрической цепи. Научно-технический вестник Поволжья. – 2018. - №5.